

1. What is the main purpose of train-test split?
 - a. To increase data size
 - b. To evaluate model performance on unseen data
 - c. To remove missing values
 - d. To create more features

Ans: b

Explanation: ট্রেন-টেস্ট স্প্লিটের মূল উদ্দেশ্য হলো মডেলকে ট্রেনিং ডেটায় শেখানো এবং টেস্টিং ডেটায় তার পারফরম্যান্স যাচাই করা। এতে ওভারফিটিং ধরা পড়ে।

2. In a dataset of 1000 rows, if test_size=0.2, how many rows go to the training set?
 - a. 200
 - b. 500
 - c. 800
 - d. 1000

Ans: c

Explanation: test_size=0.2 মানে ২০% ডেটা টেস্টিং সেটে যাবে। বাকি ৮০% (১০০০ এর ৮০০) ট্রেনিং সেটে যাবে।

3. Which parameter ensures the same split every time you run train_test_split?
 - a. test_size
 - b. shuffle
 - c. random_state
 - d. stratify

Ans: c

Explanation: random_state একটি নির্দিষ্ট সংখ্যা (যেমন 42) সেট করলে প্রতি বার একই ভাবে ডেটা ভাগ হয়। এতে গবেষণার ফলাফল পুনরায় পাওয়া যায়।

4. Which strategy is best for numerical data with outliers?
 - a. Mean
 - b. Median
 - c. Most frequent
 - d. Constant

Ans: b

Explanation: আউটলিয়ার থাকলে Mean প্রভাবিত হয়। Median আউটলিয়ার প্রতিরোধী, তাই স্কিউড ডেটা বা আউটলিয়ার থাকলে Median ব্যবহার করা ভালো।

5. Which strategy is used for categorical missing value imputation?
 - a. Mean
 - b. Median
 - c. Most frequent
 - d. Standard deviation

Ans: c

Explanation: ক্যাটাগরিক্যাল ডেটার গড় বা মিডিয়ান হয় না। তাই সবচেয়ে বেশি বার আসা মান (Mode বা Most frequent) দিয়ে মিসিং ভ্যালু পূরণ করা হয়।

6. What does add_indicator=True in SimpleImputer do?
 - a. Adds a new column showing which values were missing
 - b. Removes missing values
 - c. Scales the data
 - d. Encodes categorical data

Ans: a

Explanation: add_indicator=True একটি নতুন কলাম যোগ করে যেখানে True/False বা 1/0 দিয়ে বুঝায় কোন ভ্যালু আগে মিসিং ছিল। এতে মডেল জানতে পারে কোন ডেটা ইম্পিউট করা হয়েছে।

7. Why should you NOT fit the imputer on the test data?

- a. Test data is smaller
- b. It increases accuracy
- c. It is faster
- d. It causes data leakage

Ans: d

Explanation: টেস্ট ডেটা থেকে mean/median শিখলে টেস্ট ডেটার তথ্য ট্রেনিংয়ে চলে আসে – এটাই Data Leakage। মডেলের আসল পারফরম্যান্স বোঝা যায় না। ট্রেনিং ডেটা থেকে শিখে টেস্টে শুধু transform() করতে হয়।

8. What should you do if a column has >70% missing values?

- a. Impute with mean
- b. Impute with median
- c. Impute with most frequent
- d. Drop the column

Ans: d

Explanation: ৭০% এর বেশি মিসিং থাকলে কলামটি ইম্পিউট করা ঠিক নয় – কারণ খুব কম তথ্যের ভিত্তিতে বাকি অংশ পূরণ করলে ভুল হয়। সে ক্ষেত্রে কলাম ডিলিট করাই ভালো (যেমন Titanic-এর Cabin)।

9. What happens if you forget .ravel() after transforming a single column with SimpleImputer?

- a. Works fine
- b. Returns a 2D array and causes error when assigning to 1D column
- c. Returns a scalar
- d. Deletes the column

Ans: b

Explanation: SimpleImputer সবসময় 2D array রিটার্ন করে। একটি 1D কলামে 2D array অ্যাসাইন করতে গেলে error হয়। .ravel() বা .flatten() ব্যবহার করে 2D কে 1D বানাতে হয়।